Universidade Cruzeiro do Sul

TRABALHO DE GRADUAÇÃO INTERDISCIPLINAR I
Ciência da Computação · Coordenação de Tecnologia

EduPredict: Um Sistema Baseado em *Machine Learning* para Predição de Desempenho e Evasão Escolar

Carlos Eduardo Franco Gabriel (RGM 33060576)

Miguel Ferreira Palmieri Souza Rocha (RGM 32818793)

Orientador: **Prof. Me. João Roberto Ursino da Cruz**

Coordenação de Tecnologia — Universidade Cruzeiro do Sul (UNICSUL) · Caixa Postal 08060-070 — São Paulo — SP — Brasil

OBJETIVO

Investigar a viabilidade técnica do uso de *Machine Learning* como ferramenta de apoio à identificação de alunos em risco de evasão.

QUESTÃO DE PESQUISA

É viável usar ML para prever desempenho e risco de evasão na educação básica, com níveis aceitáveis de acurácia e confiabilidade?

1. Introdução

A evasão escolar persiste como entrave ao progresso socioeconômico. Segundo o Censo Escolar (**INEP, 2023**), cerca de **8% dos alunos do Ensino Médio** abandonam os estudos. A identificação precoce de estudantes em risco permite intervenções personalizadas e uso eficiente de recursos pedagógicos. Este trabalho aplica *Machine Learning* sobre notas e indicadores de fluxo acadêmico para antecipar desempenho e risco de evasão na educação básica.



Figura 1. Painel do EduPredict — predição de risco por aluno em apoio à gestão escolar.

2. Metodologia



3.Base de Dados e Features

1201 alunos × 13 matérias em 7 séries — **15.613 registros**. Notas N1–N4 normalizadas em [0,1] e **9 features** extraídas.

Feature	Descrição	Fórmula
`n1_norm`	1ª avaliação normalizada	`N1 / 10`
`n2_norm`	2ª avaliação normalizada	`N2 / 10`
`slope_notas`	Tendência das notas	`Δy / Δx`
`media_geral`	Desempenho médio global	`Média / 10`

Tabela 1. Principais features extraídas para os modelos preditivos.

4.Desempenho dos Modelos

Modelo	Acurácia	F1 (macro)	CV 5-fold
M1	**83,8%**	0,834	0,801 ± 0,034
M2	**92,5%**	0,925	0,886 ± 0,028
M3 ★	**94,0%**	0,940	0,912 ± 0,018

Tabela 2. Comparativo M1–M3. O M3 supera benchmarks da literatura (78%–82%).

94% acurácia (modelo M3)

0,94 F1-Score (macro)

5.Importância das Features

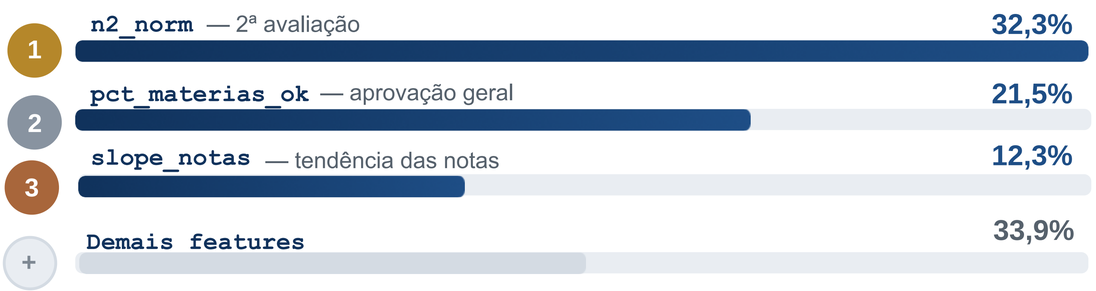


Figura 2. A 2ª avaliação concentra a maior parte do poder preditivo do modelo M3.

6.Matriz de Confusão · M3

	Prev. Aprov.	Prev. Recup.	Prev. Repro.
RealAprov.	1.284 acerto	89	27
RealRecup.	156	342 acerto	52
RealRepro.	38	45	267 acerto

Tabela 3. Acurácia por classe — Aprovado 91,7% · Recuperação 62,2% · Reprovado 76,3%. Classificações no conjunto de teste (diagonal = acertos).

7.Desempenho por Nível

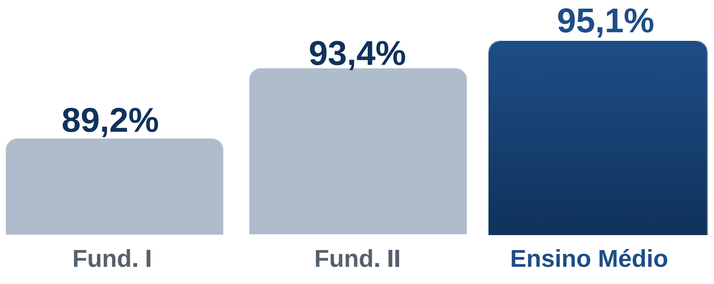


Tabela 4. Padrões mais previsíveis no Ensino Médio (R^2 = 0,503).

8. Considerações finais

- **Viabilidade técnica confirmada** — o modelo M3 atingiu 94,0% de acurácia, com baixo desvio na validação cruzada (0,912 ± 0,018).
- **Detecção de data leakage foi decisiva** — a remoção de media_pond_norm (r=0,95) e n4_norm (r=0,91) evitou overfitting artificial.
- **A 2ª avaliação é o principal preditor** — n2_norm responde por 32,3% do poder preditivo; pct_materias_ok (21,5%) reforça o perfil holístico do aluno.
- **Limitação** — ausência de indicadores socioemocionais nos dados públicos do Censo Escolar.
- **Trabalhos futuros** — questionários socioemocionais, XGBoost / Redes Neurais, dashboard web interativo e validação em larga escala.

Referências

BREIMAN,L. (2001). Random Forests. Machine Learning, 45(1), 5–32.

INEP (2023). Microdados do Censo Escolar da Educação Básica.

LIMA, A. C. (2021). Mineração de dados e ML para prevenção da evasão escolar. Dissertação, UFRN.

MELO, H. R. (2023). MAPEA: Modelo de Análise Preditiva de Estímulos de Aprendizagem. Tese, USP.

ROMERO, C.; VENTURA, S. (2020). Educational data mining and learning analytics: an updated survey. WIREs DMKD, 10(3).

VELASCO, Y. C. R. (2022). Predição de dificuldades educacionais. Revista Integralize Scientific.