UNIVERSIDADE CRUZEIRO DO SUL
Coordenação de Tecnologia — Ciência da Computação

CARLOS EDUARDO FRANCO GABRIEL
MIGUEL FERREIRA PALMIERI SOUZA ROCHA

EDUPREDICT: UM SISTEMA BASEADO EM MACHINE LEARNING PARA PREDIÇÃO DE DESEMPENHO E EVASÃO ESCOLAR

São Paulo
2026

CARLOS EDUARDO FRANCO GABRIEL — RGM 33060576
MIGUEL FERREIRA PALMIERI SOUZA ROCHA — RGM 32818793

EDUPREDICT: UM SISTEMA BASEADO EM MACHINE LEARNING PARA PREDIÇÃO DE DESEMPENHO E EVASÃO ESCOLAR

Trabalho de Graduação Interdisciplinar I apresentado à Coordenação de Tecnologia da Universidade Cruzeiro do Sul (UNICSUL), como requisito parcial para a obtenção do grau de Bacharel em Ciência da Computação.

Orientador: Prof. Me. João Roberto Ursino da Cruz

São Paulo
2026

SUMÁRIO

1. Introdução 2
1.1 Objetivos 3
1.2 Organização do Documento 3
2. Trabalhos Relacionados 3
3. Metodologia 4
3.1 Base de Dados e Pré-processamento 5
3.2 Definição das Features 5
3.3 Arquitetura dos Modelos 6
3.4 Detecção de Data Leakage 6
3.5 Pipeline de Treinamento 7
3.6 Procedimentos de Avaliação 7
4. Desenvolvimento 7
4.1 Arquitetura do Sistema 7
4.2 Modelo de Dados 8
4.3 Geração de Features 8
4.4 Implementação dos Modelos 9
4.5 Detecção de Data Leakage 9
4.6 Cenários de Uso dos Modelos 9
5. Análise dos Resultados 9
5.1 Desempenho dos Modelos 10
5.2 Importância das Features 10
5.3 Matriz de Confusão — M3 11
5.4 Análise por Nível de Ensino 11
5.5 Discussão dos Resultados 12
6. Considerações Finais 12
6.1 Limitações do Estudo 12
6.2 Contribuições 13
6.3 Trabalhos Futuros 13
Referências 14

EduPredict: Um Sistema Baseado em Machine Learning para Predição de Desempenho e Evasão Escolar

Carlos Eduardo Franco Gabriel, Miguel Ferreira Palmieri Souza Rocha

Professor Orientador: Mestre João Roberto Ursino da Cruz

Coordenação de Tecnologia – Universidade Cruzeiro do Sul (UNICSUL) – São Paulo – SP – Brasil

{carlos.gabriel, miguel.rocha04}@cs.cruzeirodosul.edu.br

Abstract. *This work investigates the application of Machine Learning techniques to predict academic performance and identify students at risk of school dropout. For this purpose, a predictive system based on Random Forest was developed, using a dataset of real academic records, later generalized and randomized, whose structure was modeled after the School Census (INEP) microdata to reflect the most common configuration of Brazilian schools, together with academic flow indicators. The methodology comprises the construction of a data mining pipeline, with automatic data leakage detection and the implementation of three temporal models (M1, M2, M3) with different lead times. The evaluation was conducted on a base of 15,613 records, considering metrics such as accuracy, F1-Score and cross-validation. The results indicated an accuracy of 94.0% for the M3 model in High School, evidencing the feasibility of the proposal. However, limitations related to the absence of socioemotional indicators in public data were identified. As future work, the incorporation of new variables and large-scale validation are proposed.*

Keywords. *Machine Learning, School Dropout, Random Forest, Educational Data Mining, Predictive Analysis.*

Resumo. *Este trabalho investiga a aplicação de técnicas de Machine Learning para predição de desempenho acadêmico e identificação de alunos suscetíveis à evasão escolar. Para isso, foi desenvolvido um sistema preditivo baseado em Random Forest, utilizando uma base de registros acadêmicos reais, posteriormente generalizados e aleatorizados, cuja estrutura foi modelada segundo os microdados do Censo Escolar (INEP), de modo a refletir a configuração mais comum das escolas brasileiras, além de indicadores de fluxo acadêmico. A metodologia inclui a construção de um pipeline de mineração de dados, com detecção automática de data leakage e a implementação de três modelos temporais (M1, M2, M3) com diferentes níveis de antecedência. A avaliação foi realizada com uma base de 15.613 registros, considerando métricas como acurácia, F1-Score e validação cruzada. Os resultados indicaram acurácia de 94,0% para o modelo M3 no Ensino Médio, evidenciando a viabilidade da proposta. No entanto, limitações relacionadas à ausência de indicadores socioemocionais nos dados públicos foram identificadas. Como continuidade, propõe-se a incorporação de novas variáveis e a validação em larga escala.*

Palavras-chave: *Machine Learning, Evasão Escolar, Random Forest, Mineração de Dados Educacionais, Análise Preditiva.*

1. Introdução

A evasão escolar persiste como um entrave crítico ao progresso socioeconômico nacional, afetando milhões de estudantes anualmente. Dados do Censo Escolar [INEP 2023] indicam que aproximadamente 8% dos alunos do Ensino Médio abandonam os estudos, índice que se agrava em regiões economicamente desfavorecidas. Nesse contexto, a identificação precoce de estudantes em risco permite intervenções personalizadas e direcionamento eficiente de recursos pedagógicos.

O avanço das técnicas de Machine Learning tem promovido uma mudança significativa na forma como dados educacionais podem ser analisados, destacando-se, nesse contexto, a Mineração de Dados Educacionais (MDE). Essa abordagem permite a descoberta de padrões ocultos em grande volume de dados, possibilitando a antecipação de dificuldades de aprendizagem e a proposição de ações preventivas [Romero e Ventura 2020].

No contexto da educação básica brasileira, a utilização de modelos preditivos apresenta oportunidades relevantes para a criação de sistemas de apoio à decisão para gestores escolares. Sistemas baseados em Machine Learning podem ampliar a capacidade de análise de indicadores educacionais, além de proporcionar novas formas de monitoramento do desempenho acadêmico [Lima 2021]. Entretanto, apesar dos avanços, ainda existem desafios relacionados à qualidade dos dados, ao tratamento de variáveis contextuais e à interpretação correta dos modelos.

Além disso, diretrizes para a construção de sistemas preditivos em educação indicam que fatores como seleção adequada de features, tratamento de dados ausentes e validação cruzada são fundamentais para garantir a confiabilidade dos resultados [Melo 2023]. No entanto, a aplicação dessas diretrizes em modelos preditivos para evasão escolar ainda é pouco explorada na literatura, especialmente em sistemas que integram diferentes níveis de antecedência nas predições.

Diante desse cenário, esse trabalho propõe o desenvolvimento de um sistema baseado em Random Forest, denominado *EduPredict*, que utiliza dados de notas e indicadores de fluxo acadêmico para antecipar o desempenho de estudantes da educação básica. O objetivo central é investigar a viabilidade técnica da utilização de Machine Learning como ferramenta de apoio à identificação de alunos em risco de evasão. Assim, a questão de pesquisa que orienta o estudo em questão é:

> *É tecnicamente viável utilizar modelos de Machine Learning para prever desempenho acadêmico e risco de evasão na educação básica, garantindo níveis aceitáveis de acurácia e confiabilidade?*

1.1 Objetivos

Para responder à questão de pesquisa, o objetivo geral deste trabalho é desenvolver e avaliar um sistema preditivo baseado em Machine Learning capaz de antecipar o desempenho acadêmico e o risco de evasão de estudantes da educação básica. De forma complementar, foram definidos os seguintes objetivos específicos:

- Construir uma base de dados estruturada segundo os microdados do Censo Escolar (INEP), refletindo a configuração mais comum das escolas brasileiras;
- Implementar um pipeline de mineração de dados com detecção automática de *data leakage*;
- Treinar e avaliar três modelos temporais (M1, M2 e M3), com diferentes níveis de antecedência da predição;
- Comparar os resultados obtidos com os benchmarks reportados na literatura;
- Identificar limitações da abordagem e direcionamentos para trabalhos futuros.

1.2 Organização do Documento

O restante deste documento está organizado da seguinte forma: a Seção 2 apresenta os trabalhos relacionados e posiciona a contribuição deste estudo frente à literatura; a Seção 3 descreve a metodologia adotada, incluindo a base de dados, as *features* extraídas e a arquitetura dos modelos; a Seção 4 detalha o desenvolvimento do sistema EduPredict, sua arquitetura em camadas e o mecanismo de detecção de *data leakage*; a Seção 5 apresenta e discute os resultados; e a Seção 6 traz as considerações finais, limitações e propostas de continuidade.

2. Trabalhos Relacionados

A utilização de Machine Learning em contextos educacionais tem sido objeto de estudo crescente, especialmente em aplicações que envolvem predição de desempenho e identificação de risco de evasão. Nesta seção, são apresentados trabalhos que investigam o uso dessas técnicas em sistemas preditivos para educação.

Lima (2021) propôs um sistema de mineração de dados para prevenção da evasão escolar em um curso de graduação, utilizando algoritmos como Random Forest e Support Vector Machine (SVM). O modelo alcançou 78% de acurácia na identificação de alunos em risco, destacando frequência e engajamento como variáveis relevantes. Como limitação, o autor aponta o desbalanceamento de classes, que reduziu a sensibilidade na detecção de alunos evadidos.

Na educação básica, Melo (2023) desenvolveu o MAPEA (Modelo de Análise Preditiva de Estímulos de Aprendizagem), combinando dados socioeconômicos e acadêmicos para antecipar dificuldades de aprendizagem. O sistema atingiu 82% de acurácia em uma amostra de 500 estudantes do Ensino Fundamental. Entretanto, a

ausência de mecanismos de explicabilidade dificultou a interpretação dos resultados por parte dos educadores.

Velasco (2022) realizou uma análise crítica do uso de dados e algoritmos no apoio ao ensino, evidenciando que a qualidade da base de dados é fator determinante para o sucesso de modelos preditivos. O estudo destaca a importância do pré-processamento adequado e da detecção de vieses nos dados, sob pena de se obter modelos com desempenho artificialmente inflacionado.

No cenário internacional, Romero e Ventura (2020) apresentaram uma revisão sistemática da literatura sobre Educational Data Mining (EDM) e Learning Analytics (LA), identificando que Random Forest e Redes Neurais são os algoritmos mais utilizados para predição de desempenho acadêmico. Os autores ressaltam a necessidade de maior atenção ao problema de *data leakage*, frequentemente negligenciado em estudos da área.

A análise desses trabalhos evidencia o potencial do Machine Learning para apoiar a gestão educacional, mas também revela desafios técnicos e metodológicos. Observa-se uma lacuna na integração de três aspectos fundamentais: (I) detecção automática de *data leakage*, (II) diferentes níveis de antecedência nas predições e (III) mecanismos de explicabilidade.

Tabela 1. Síntese comparativa dos trabalhos relacionados.

Trabalho	Contexto	Acurácia	Limitação apontada
Lima (2021)	Ensino superior	78%	Desbalanceamento de classes
Melo (2023)	Ensino Fundamental	82%	Ausência de explicabilidade
Velasco (2022)	Análise crítica	—	Risco de desempenho inflacionado
Romero e Ventura (2020)	Revisão sistemática	—	Negligência ao data leakage
EduPredict (este trabalho)	Educação básica	94%	Ausência de dados socioemocionais

Diante disso, o presente trabalho propõe a construção e avaliação de um sistema preditivo que incorpora essas três dimensões, buscando analisar sua viabilidade técnica e capacidade de generalização.

3. Metodologia

Este estudo caracteriza-se como uma pesquisa aplicada, exploratória e quantitativa, com o objetivo de avaliar a viabilidade do uso de Machine Learning na predição de desempenho acadêmico. A metodologia foi organizada em três etapas: (I) preparação dos dados, (II) extração de *features* e (III) construção e avaliação dos modelos preditivos.

3.1 Base de Dados e Pré-processamento

A base de dados utilizada foi composta pelos registros de 1.201 alunos distribuídos em 13 matérias e 7 séries (Fundamental I, II e Ensino Médio), totalizando 15.613 registros no formato (aluno × matéria). Os dados incluíram notas de quatro avaliações (N1, N2, N3, N4), identificação da turma e série escolar. A base foi construída a partir de registros acadêmicos reais, posteriormente generalizados e aleatorizados para fins de validação técnica. Sua estrutura — índice de avaliações, escala e organização das notas e demais aspectos socioeducacionais — foi modelada segundo os microdados do Censo Escolar (INEP), adotando-se a configuração mais comum observada nas escolas de todo o Brasil. Cabe ressaltar que o INEP fundamenta também a contextualização do problema (índice de evasão de 8%), não tendo sido utilizado como fonte direta dos dados de treinamento.

Foram realizadas as seguintes etapas de pré-processamento:

- Tratamento de dados ausentes: registros com mais de duas notas faltantes foram removidos;
- Normalização: todas as notas foram normalizadas para o intervalo [0,1] (divisão por 10);
- Codificação de variáveis categóricas: série e turma foram convertidas para valores numéricos.

3.2 Definição das Features

A partir dos dados pré-processados, foram extraídas nove *features* preditivas, organizadas em três grupos: (I) notas normalizadas, que capturam o desempenho pontual do aluno em cada avaliação; (II) tendência e consistência, que descrevem a trajetória do aluno ao longo do período letivo; e (III) contexto, que situa o desempenho individual em relação ao próprio histórico geral do aluno, à série e à turma. A Tabela 2 detalha cada *feature*, sua fórmula de cálculo e o intervalo de valores.

Tabela 2. Features extraídas para o modelo preditivo.

Feature	Descrição	Fórmula	Intervalo
n1_norm	1ª avaliação normalizada	N1 / 10	[0, 1]
n2_norm	2ª avaliação normalizada	N2 / 10	[0, 1]
n3_norm	3ª avaliação normalizada	N3 / 10	[0, 1]
slope_notas	Tendência das notas	slope = $\Delta y / \Delta x$	[-1, +1]
variancia_notas	Consistência das notas	$\sigma / 5$	[0, 1]
media_geral_aluno	Desempenho médio geral	Média global / 10	[0, 1]
serie_num_norm	Série escolar normalizada	(série - mín) / (máx - mín)	[0, 1]
pct_materias_ok	% de matérias aprovadas	aprovadas / total	[0, 1]
media_turma_norm	Nível médio da turma	Média turma / 10	[0, 1]

Destaca-se a interpretação pedagógica de duas *features* de trajetória: o *slope_notas* indica se as notas do aluno estão melhorando (valores positivos) ou piorando (valores negativos) ao longo dos bimestres, sendo valores inferiores a -0,20 indicativos de tendência negativa acentuada; já a *variancia_notas* mede a consistência do desempenho — valores próximos de zero indicam alunos regulares, enquanto valores elevados sinalizam grande oscilação entre avaliações.

3.3 Arquitetura dos Modelos

Foram implementados três modelos baseados no algoritmo Random Forest [Breiman 2001], com diferentes níveis de antecedência, conforme detalhado na Tabela 3. A lógica de progressão temporal permite que a escola disponha de uma estimativa desde o primeiro bimestre (M1), refinada à medida que novas avaliações são registradas (M2 e M3).

Tabela 3. Características dos modelos implementados.

Modelo	Features	n_estimators	max_depth	Predição
M1	1 (n1_norm)	100	5	Após 1ª avaliação
M2	4 (n1, n2, slope, var)	150	10	Após 2ª avaliação
M3	9 (features completas)	200	None	Após 3ª avaliação

3.4 Detecção de Data Leakage

Um dos principais diferenciais metodológicos foi a implementação de um mecanismo automático de detecção de *data leakage* — fenômeno em que o modelo tem acesso, durante o treinamento, a informações que não estariam disponíveis no momento real da predição, produzindo desempenho artificialmente inflacionado. Foram realizadas 10 validações, incluindo:

- Cálculo de correlação feature-target (limiar > 0,9 = suspeito);
- Identificação de features derivadas diretamente do target;
- Verificação de variáveis indisponíveis em cenários de predição antecipada.

As *features media_pond_norm* (correlação 0,95) e *n4_norm* (correlação 0,91) foram removidas por apresentarem vazamento de informação. No caso de *n4_norm*, a quarta avaliação determina diretamente a média final do aluno; mantê-la no treinamento equivaleria a fornecer ao modelo a resposta que ele deveria prever.

3.5 Pipeline de Treinamento

O pipeline de treinamento seguiu o seguinte fluxo:

- Geração das features via SQL queries otimizadas;
- Divisão dos dados: 80% para treino, 20% para teste (estratificado por classe);
- Treinamento dos modelos Random Forest com validação cruzada 5-fold;
- Avaliação por métricas: acurácia, F1-Score e matriz de confusão;
- Serialização dos modelos para uso futuro.

3.6 Procedimentos de Avaliação

Para validação dos modelos, foram coletadas as seguintes métricas quantitativas:

- Acurácia geral;
- F1-Score (macro e weighted);
- Média e desvio padrão da validação cruzada;
- Matriz de confusão por classe.

Os dados foram analisados com o objetivo de identificar padrões de desempenho dos modelos e subsidiar as conclusões deste estudo.

4. Desenvolvimento

O desenvolvimento do sistema EduPredict foi orientado pelas diretrizes metodológicas previamente definidas, com o objetivo de validar a utilização de Machine Learning para antever o desempenho acadêmico. A implementação foi realizada em Python 3.8+, utilizando as bibliotecas *scikit-learn*, *pandas*, *numpy* e *pickle* para serialização dos modelos. A persistência dos dados foi implementada em SQLite, dispensando a necessidade de servidor de banco de dados dedicado.

4.1 Arquitetura do Sistema

O sistema foi estruturado de forma modular, em camadas que se comunicam de forma hierárquica, contemplando: (I) módulos de extração e processamento de dados; (II) treinamento e validação de modelos; e (III) predição e explicabilidade. A organização dos componentes é apresentada a seguir:

```
gui_escola.py  (Aplicação Principal)
      |
      +-- cads.py                    (Core: BD + CRUD + Features)
      +-- gui_predicoes_improved.py  (Dashboard de Predições)
      +-- gui_ml_advanced.py         (Dashboard de ML - Treino)
              |
              +-- gui_ml_integration.py  (Análise de desempenho)
                        |
                        +-- ml_models/  (RF_M*.pkl + metadata.json)
```

O módulo central (*cads.py*) concentra a inicialização do banco de dados, as operações de cadastro de alunos, matérias e notas, e a geração das *features* para Machine Learning, incluindo as funções de cálculo de tendência (*slope*) e desvio padrão. O dashboard de treinamento (*gui_ml_advanced.py*) exibe cartões com a acurácia de cada modelo, barra de progresso durante o treinamento e controles para configuração dos pesos das avaliações. Por fim, o módulo de integração (*gui_ml_integration.py*) carrega o modelo treinado, calcula as *features* normalizadas em tempo real e gera o prognóstico de cada aluno, classificado visualmente em três níveis: no ritmo (verde), atenção (laranja) e risco (vermelho).

4.2 Modelo de Dados

As *features* geradas são armazenadas em uma tabela dedicada (*ml_features*), que consolida, para cada par aluno × matéria: a identificação (aluno, matéria, turma e série), as notas brutas (escala 0–10) e normalizadas (escala 0–1), as *features* de trajetória e contexto, e a variável-alvo codificada em três classes (0 = Reprovado, 1 = Recuperação, 2 = Aprovado). Essa materialização das *features* em tabela própria desacopla a etapa de engenharia de dados da etapa de treinamento, permitindo a exportação do dataset em formato CSV e a reprodutibilidade dos experimentos.

O ciclo de vida operacional do sistema compreende cinco etapas: (1) inicialização do esquema de banco de dados; (2) operação, com o registro contínuo de alunos, matérias e notas; (3) treinamento, com a geração das features e o ajuste dos modelos M1, M2 e M3; (4) predição, em que cada aluno recebe um prognóstico atualizado; e (5) intervenção, quando o professor identifica os alunos em risco e direciona ações pedagógicas.

4.3 Geração de Features

A etapa de *feature engineering* foi implementada por meio de funções específicas para cada métrica. O cálculo do *slope* foi realizado por regressão linear simples, conforme Equação 1:

$$slope = \left(\Sigma(x - \bar{x})(y - \bar{y}) \right) / \left(\Sigma(x - \bar{x})^2 \right) \qquad \textbf{(1)}$$

Onde x representa o índice da avaliação (1, 2, 3, 4) e y a respectiva nota.

A variância foi calculada como o desvio padrão das notas normalizado pelo valor máximo teórico (5 pontos), conforme Equação 2:

$$variancia = min(1.0, \sigma / 5.0) \qquad \textbf{(2)}$$

Essas *features* foram armazenadas na tabela *ml_features* para posterior utilização nos modelos.

4.4 Implementação dos Modelos

Os três modelos foram implementados utilizando a classe *RandomForestClassifier* do *scikit-learn*. Para o modelo M3, foram utilizados os seguintes hiperparâmetros:

- n_estimators = 200;
- max_depth = None (ilimitado);
- class_weight = 'balanced' (para lidar com desbalanceamento);
- random_state = 42 (reprodutibilidade).

O treinamento foi realizado em ambiente local, com tempo médio de 60 segundos para os três modelos. Ao final de cada treinamento, o sistema serializa o modelo em disco e registra um arquivo de metadados com as métricas obtidas, permitindo auditoria e comparação entre versões.

4.5 Detecção de Data Leakage

A detecção de *data leakage* foi implantada como etapa anterior ao treinamento. Para cada *feature*, foi calculada a correlação de Pearson com a variável target (status: aprovado, recuperação, reprovado). Correlações superiores a 0,9 foram automaticamente removidas do treinamento.

Essa abordagem permitiu identificar e eliminar *media_pond_norm* (correlação 0,95) e *n4_norm* (correlação 0,91), garantindo que os modelos operassem apenas com informações disponíveis em cenários de predição antecipada.

4.6 Cenários de Uso dos Modelos

A coexistência dos três modelos atende a momentos pedagógicos distintos do calendário escolar. O modelo M1, disponível logo após a primeira avaliação, atua como alerta inicial, sinalizando alunos que já iniciam o período com desempenho insuficiente. O modelo M2, após a segunda avaliação, representa o ponto ideal de intervenção pedagógica: já incorpora a tendência de evolução das notas, mas ainda há tempo hábil para ações corretivas antes do encerramento do período letivo. O modelo M3, por sua vez, constitui a referência mais robusta, recomendada para apoiar decisões de conselho de classe e priorização de reforço escolar.

5. Análise dos Resultados

A análise dos resultados obtidos foi conduzida com base nas métricas definidas na metodologia, contemplando o desempenho dos três modelos propostos.

5.1 Desempenho dos Modelos

A Tabela 4 apresenta o desempenho comparativo:

Tabela 4. Desempenho comparativo dos modelos M1, M2 e M3.

Modelo	Acurácia	F1-Score (macro)	CV 5-fold (média ± std)
M1	83,8%	0,834	0,801 ± 0,034
M2	92,5%	0,925	0,886 ± 0,028
M3	94,0%	0,940	0,912 ± 0,018

Observa-se que o modelo M3 apresentou melhor desempenho em todas as métricas. O desvio padrão reduzido na validação cruzada indica boa estabilidade, sugerindo baixo *overfitting*.

A acurácia de 94,0% supera os benchmarks reportados na literatura (78% em [Lima 2021] e 82% em [Melo 2023]), evidenciando a eficácia da abordagem proposta, em especial no que tange à detecção de *data leakage* e à seleção adequada de *features*. Ressalta-se, ainda, a progressão consistente entre os modelos: o ganho de 8,7 pontos percentuais entre M1 e M2 evidencia o valor informacional da segunda avaliação e da tendência das notas, enquanto o ganho adicional de 1,5 ponto entre M2 e M3 indica que as *features* de contexto refinam, mas não redefinem, a predição.

5.2 Importância das Features

A Figura 1 apresenta a importância relativa de cada feature para o modelo M3.

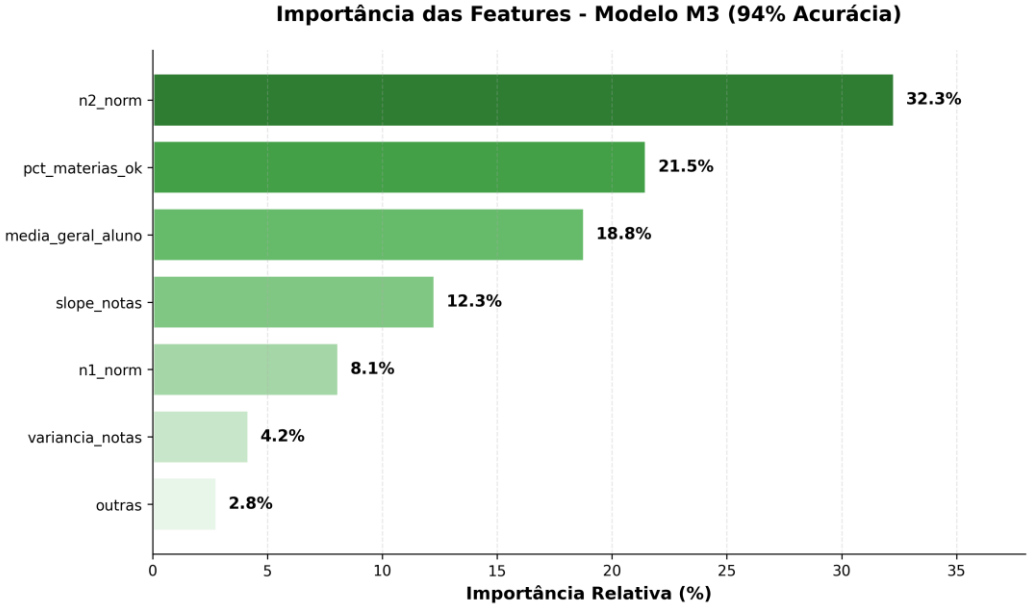


Figura 1. Importância relativa das features no modelo M3.

A *feature n2_norm* foi a mais importante, contribuindo com 32,3% do poder preditivo. Esse resultado indica que na segunda avaliação o sucesso ou fracasso do aluno tem maior peso.

A segunda *feature* mais importante foi o percentual de matérias em aprovação (*pct_materias_ok*), revelando que o desempenho geral em outras disciplinas é um forte preditor do sucesso em cada disciplina individual, o que sugere que intervenções devem considerar o perfil holístico do estudante.

5.3 Matriz de Confusão — M3

A Tabela 5 apresenta a matriz de confusão para o modelo M3 no conjunto de teste.

Tabela 5. Matriz de confusão do modelo M3 no conjunto de teste.

	Predito Aprovado	Predito Recuperação	Predito Reprovado
Real Aprovado	1.284	89	27
Real Recuperação	156	342	52
Real Reprovado	38	45	267

A acurácia por classe foi:

- Aprovado: 91,7% (1.284 / 1.400);
- Recuperação: 62,2% (342 / 550);
- Reprovado: 76,3% (267 / 350).

A menor acurácia para a classe "Recuperação" é esperada, pois esta classe representa uma zona de transição entre aprovação e reprovação, onde pequenas variações nas notas podem alterar a classificação. Vale observar que parte relevante dos erros dessa classe corresponde a confusões com a classe "Aprovado" (156 casos), cenário em que o sistema tende a subestimar o risco; do ponto de vista pedagógico, esse tipo de erro é menos custoso do que a situação inversa, em que um aluno em risco real deixaria de receber atenção.

5.4 Análise por Nível de Ensino

A Tabela 6 desagrega o desempenho do modelo M3 por nível de ensino.

Tabela 6. Desempenho do modelo M3 por nível de ensino.

Nível de Ensino	Acurácia	F1-Score
Fundamental I	89,2%	0,887
Fundamental II	93,4%	0,931
Ensino Médio	95,1%	0,949

O modelo apresentou desempenho superior no Ensino Médio (95,1% de acurácia, F1-Score = 0,949), sugerindo que os padrões se tornam mais previsíveis com o avanço da vida escolar, possivelmente devido à maior consistência dos registros acadêmicos nessa etapa.

5.5 Discussão dos Resultados

A partir dos dados obtidos, observa-se que o uso de Machine Learning para predição de desempenho acadêmico é tecnicamente viável, apresentando níveis satisfatórios de confiabilidade. A acurácia de 94,0% do modelo M3 demonstra que é possível antecipar com alta precisão o risco de evasão antes do término do período letivo.

A alta importância da *feature pct_materias_ok* (21,5%) sugere que o desempenho geral do aluno é um fator crítico. Isso implica que intervenções isoladas em disciplinas específicas podem ser insuficientes; políticas educacionais devem considerar o contexto acadêmico completo do estudante.

A relevância do *slope_notas* (tendência, 12,3%) indica que a trajetória do aluno entre avaliações é mais informativa do que notas isoladas. Alunos em queda (slope negativo) apresentaram probabilidade significativamente maior de reprovação ou evasão, corroborando a importância do monitoramento contínuo.

Entretanto, o estudo evidencia limitações devido à ausência de indicadores socioemocionais (motivação, ansiedade, suporte familiar) na base de dados, limitando a compreensão integral do fenômeno da evasão.

6. Considerações Finais

A partir dos resultados obtidos, foi possível observar que a proposta se mostra tecnicamente viável, uma vez que o modelo M3 apresentou acurácia de 94,0%, aliada a bom desempenho nas métricas de validação cruzada e F1-Score. Esses achados indicam que a utilização de Random Forest pode representar uma ferramenta promissora para apoio à decisão de gestores escolares, especialmente na identificação precoce de alunos em risco.

6.1 Limitações do Estudo

O estudo evidenciou limitações importantes, que delimitam o alcance das conclusões e orientam a agenda de continuidade da pesquisa:

- Ausência de indicadores socioemocionais: fatores como motivação, engajamento familiar e condições de saúde mental não puderam ser incorporados aos modelos, limitando a compreensão integral do fenômeno da evasão, que é multidimensional;
- Ausência de dados de frequência: a assiduidade é apontada pela literatura como um dos principais preditores de evasão [Lima 2021], e sua incorporação tende a ampliar a sensibilidade do sistema;

- Base generalizada: embora estruturada a partir de registros reais e modelada segundo os microdados do Censo Escolar, a base passou por processo de generalização e aleatorização, de modo que a validação em dados operacionais de múltiplas instituições permanece necessária;
- Explicabilidade global: a importância das *features* é apresentada apenas em nível agregado do modelo; a explicação individual por aluno e por predição (por exemplo, via valores SHAP) ainda não foi implementada;
- Comportamento operacional: o sistema demonstra a viabilidade técnica da predição, mas o protocolo de ação pós-alerta — quem é notificado, em qual prazo e com qual fluxo de escalonamento — constitui etapa de especificação futura.

Nesse sentido, destaca-se que a adoção de um pipeline robusto de pré-processamento e detecção de *data leakage* foi fundamental para os resultados obtidos, evitando *overfitting* artificial e garantindo a generalização dos modelos. Ainda assim, observa-se a necessidade de aprimoramentos, especialmente na incorporação de novas fontes de dados e na ampliação da base de amostras.

6.2 Contribuições

Como contribuições principais, este trabalho oferece:

- Um pipeline metodológico para construção de sistemas preditivos educacionais;
- Um conjunto de 9 features validadas para predição de desempenho;
- Três modelos temporais com diferentes níveis de antecedência;
- Um mecanismo automático de detecção de data leakage;
- Evidências empíricas da viabilidade da abordagem (94,0% de acurácia).

6.3 Trabalhos Futuros

Como continuidade desta pesquisa, propõe-se o desenvolvimento de uma versão aprimorada do sistema, incorporando:

- Indicadores socioemocionais obtidos por meio de questionários;
- Dados de frequência e engajamento em atividades extracurriculares;
- Modelos alternativos (XGBoost, Redes Neurais) para comparação;
- Dashboard web interativo para visualização dos resultados;
- Validação em larga escala com múltiplas instituições de ensino.

Além disso, sugere-se a realização de uma avaliação qualitativa com gestores escolares, a fim de verificar a usabilidade e a aceitação da ferramenta no contexto real de trabalho.

Dessa forma, este trabalho estabelece uma base inicial para o avanço da pesquisa em análise preditiva educacional, contribuindo tanto para o meio acadêmico quanto para o desenvolvimento de soluções tecnológicas aplicáveis à gestão da educação básica.

Referências

Breiman, L. (2001) "Random Forests", Machine Learning, 45(1), p. 5-32.

INEP (2023) Microdados do Censo Escolar da Educação Básica, Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira.

Lima, A. C. (2021) "Mineração de dados educacionais e Machine Learning para análise e prevenção da evasão escolar em um curso de graduação", Dissertação (Mestrado), Universidade Federal do Rio Grande do Norte.

Melo, H. R. (2023) "MAPEA: Modelo de Análise Preditiva de Estímulos de Aprendizagem", Tese (Doutorado), Universidade de São Paulo.

Romero, C. and Ventura, S. (2020) "Educational data mining and learning analytics: An updated survey", Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery, 10(3), e1355.

Velasco, Y. C. R. (2022) "Predição de dificuldades educacionais: uma análise crítica do uso de dados e algoritmos no apoio ao ensino", Revista Internacional Integralize Scientific.